第 8 天 · 11/9 · 今日知识点回顾

numpy：ndarray、向量化、广播、布尔索引

目标：不用 for 循环，把一份 1200 行的金额列一次性做完「解析 + 判空 + 缩放 + 条件筛选」。

对着 B 站视频看：视频讲到的每一句，这张 PPT 里都有一条；复习时只翻这份，不用再回去翻分P。

今天结束时，你应该能做到

验收标准（做到这句就算过关）

- 不用 for 循环，把一份 1200 行的金额列一次性做完「解析 + 判空 + 缩放 + 条件筛选」。

今天的做法（顺序别颠倒）

- 题库地址：file:///D:/DSH工作区/00-学习中心/60-练习环境/Python-Env/data
- 做完记一句：今天卡在哪、错在哪 → 写进 3-每日打卡。

今天看哪几集、读哪一章

这一天的知识：4 集 • 合计约 97 分钟（边看边在本机敲一遍）

P14	numpy的数组的创建	约 16 分钟
P15	数组的计算和数组的计算	约 42 分钟
P17	numpy中的索引和切片	约 18 分钟
P21	numpy中的nan和常用统计方法	约 21 分钟

教材（已下载到 20-教材与讲义\python-data\，断网也能看）

`https://raw.githubusercontent.com/datawhalechina/joyful-pandas/master/source/Content/ch1.rst`

第一章 预备知识：列表推导式、匿名函数、numpy 基础

视频地址就在下面的「今天做哪些题」网页里，点一下直达分P。

知识点 1/7 • ndarray 是「同类型 + 定长」的数组，这是它快的原因

- 一句话：一个 ndarray 里所有元素类型相同，内存连续，所以整列运算能一次性算完。
- 代码：

```
import numpy as np
a = np.array([1, 2, 3, 4])
print(a.dtype, a.shape, a.ndim)      # int64 (4,) 1
b = np.array([[1, 2, 3], [4, 5, 6]])
print(b.shape)                        # (2, 3)  2 行 3 列
print(b.dtype)
```

★ np.array([1, 2, 3.5]) 会整体变成 float64 —— 一个 float 就把全数组升成 float。

- 这和 Python 的 list 完全不同（list 里什么都能混）。

知识点 2/7 • 向量化：不写 for，整列一起算

- 一句话：a + 1、a * 2、a > 3 都是「对每个元素做同一件事」，不用循环。
- 代码：

```
a = np.array([1, 2, 3, 4])
print(a + 1)         # [2 3 4 5]
print(a * 2)         # [2 4 6 8]
print(a > 2)         # [False False  True  True]
print(a[a > 2])      # [3 4]      ← 布尔索引
print(a.sum(), a.mean(), a.max(), a.std())
```

★ 不要写 for i in range(len(a)): b[i] = a[i] * 2 —— 1200 行时差别不明显，到 120 万行时慢 100 倍以上。向量化是 pandas 快过 Excel 的根源。

知识点 3/7 • 广播：形状不同也能算，但有规则

- 一句话：从右往左比形状，要么相等、要么其中一个是 1，否则报错。
- 代码：

```
m = np.array([[1, 2, 3], [4, 5, 6]])     # shape (2,3)
print(m + 10)                             # 标量广播：每个元素 +10
print(m + np.array([10, 20, 30]))         # (3,) 广播到每一行
print(m + np.array([[10], [20]]))         # (2,1) 广播到每一列
# m + np.array([1, 2])                    # ValueError: operands could not be broadcast
```

★ 报错原文：ValueError: operands could not be broadcast together with shapes (2,3) (2,)

- —— 最后一位 3 和 2 既不相等也不是 1，所以失败。看报错先看 shapes。

知识点 4/7 • nan 是「缺失值」，它和任何数比较都是 False

- 一句话：np.nan != np.nan，判空要用 np.isnan() 或 pd.isna()。
- 代码：

```
a = np.array([1.0, np.nan, 3.0])
print(a.sum(), a.mean())         # nan nan   ← 一个 nan 污染整个统计
print(np.nansum(a), np.nanmean(a))   # 4.0 2.0  ← nansum/nanmean 跳过 nan
print(np.isnan(a))               # [False  True False]
print(a == a)                    # [ True False  True]   ← nan 自己都不等于自己
```

★ a == np.nan 永远全 False，a != np.nan 永远全 True —— 这是最经典的错。

- 真实数据里 nan 有三种来源：空字符串、'NULL'、Excel 空单元格，读进来都会变 nan。

这一页只讲「nan 是「缺失值」，它和任何数比较都是 False」。讲完就翻页，下一页是另一个知识点。

知识点 5/7 • 真数据上手：把 amount 列解析成数字数组

- 一句话：str.replace 在 numpy 里也能向量化（np.char 或 pd 的字符串方法），但更快的是 pandas。
- 代码：

```
import numpy as np, pandas as pd, pathlib
DATA = pathlib.Path(r'D:\DSH工作区\00-学习中心\60-练习环境\Python-Env\data')
s = pd.read_csv(DATA / 'orders_dirty.csv')['amount']
num = pd.to_numeric(s.astype(str).str.replace('¥', '', regex=False)
.str.replace(',', '', regex=False), errors='coerce')
print(len(num), num.isna().sum(), round(num.sum(), 2))
```

- （本机实测：1200 行里 35 行金额为空 → 解析后 35 个 nan；
- 全列合计 1,199,463.00。这个数第 12 天 groupby 之后还会再出现一次，如果两次对不上，就是清洗口径变了。）

知识点 6/7 • 形状变换：reshape / 转置 / 拼接

- 一句话：reshape 改形状不改数据；.T 转置；concatenate 按轴拼。
- 代码：

```
a = np.arange(6)
print(a.reshape(2, 3))
print(a.reshape(2, 3).T)                  # 转置
print(np.concatenate([a, a]))             # 拼成一维 12 个
print(np.vstack([a.reshape(2, 3), a.reshape(2, 3)]))   # 竖着摞，变成 4 行
```

★ reshape 的元素个数必须对得上，否则报ValueError: cannot reshape array of size 6 into shape (4,2)。

- 先用 a.size 算一下再 reshape。

知识点 7/7 • numpy 2.x 删了一堆别名，别再抄老教程

- 一句话：np.float_ / np.NaN / np.Inf / np.unicode_ / np.in1d / np.trapz 在本机 2.5.4 上全部 AttributeError。
- 代码：

```
import numpy as np
print(np.__version__)        # 2.5.4
# np.float_          → AttributeError: module 'numpy' has no attribute 'float_'
# np.NaN             → AttributeError
# np.in1d            → AttributeError（改用 np.isin）
# np.trapz           → AttributeError（改用 np.trapezoid）
```

★ 本机实测确认过的替代：np.float64 / np.nan / np.inf / np.str_ / np.isin / np.trapezoid。

- 抄 B 站 2020 年的代码前，先看它用的是哪个版本。

代码速查：今天这几段，要在本机跑通（1/5）

写一个 numpy_probe.py，把下面每一条都跑出真实数字：

```
import numpy as np, pandas as pd, pathlib
```

```
DATA = pathlib.Path(r'D:\DSH工作区\00-学习中心\60-练习环境\Python-Env\data')
```

```
df = pd.read_csv(DATA / 'orders_dirty.csv')
```

1) 向量化：quantity 列整体判断

q = df['quantity'].to_numpy()

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

代码速查：今天这几段，要在本机跑通（2/5）

```
print('数量为负的行数：', (q < 0).sum())          # 应为 25
```

```
print('数量分布：', np.unique(q, return_counts=True))
```

2) 广播：给每个金额打九折

```
num = pd.to_numeric(df['amount'].astype(str).str.replace('¥', '', regex=False)
```

```
                    .str.replace(',', '', regex=False), errors='coerce')
```

arr = num.to_numpy()

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

代码速查：今天这几段，要在本机跑通（3/5）

```
print('九折后合计：', round(np.nansum(arr) * 0.9, 2))
```

3) nan 处理：三种统计口径对比

```
print('含 nan 直接 sum：', arr.sum())
```

```
print('nansum：', round(np.nansum(arr), 2))
```

```
print('nan 个数：', np.isnan(arr).sum())          # 应为 35
```

4) 布尔索引：筛出金额 > 2000 的行

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

代码速查：今天这几段，要在本机跑通（4/5）

big = df[num > 2000]

```
print('金额 > 2000 的行数: ', len(big))
```

```
print(big[['order_id', 'amount']].head(3).to_string(index=False))
```

验收（做到才算过关）：

① 数量为负的行数 = 25，nan 个数 = 35，两个数都要对上；

```
② 能说清 arr.sum() 为什么是 nan，而 np.nansum 能给出数；
```

代码速查：今天这几段，要在本机跑通（5/5）

③ 把 `(q < 0).sum()` 改成 `sum(q < 0)`，看结果一样吗，并解释为什么。

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

最容易错的地方

★ 不要写 for i in range(len(a)): b[i] = a[i] * 2 —— 1200 行时差别不明显，到 120 万行时慢 100 倍以上。向量化是 pandas 快过 Excel 的根源。

★ 报错原文：ValueError: operands could not be broadcast together with shapes (2,3) (2,)

—— 最后一位 3 和 2 既不相等也不是 1，所以失败。看报错先看 shapes。

★ a == np.nan 永远全 False，a != np.nan 永远全 True —— 这是最经典的错。

这些句子都是「差一个字、结果差一截」的地方，考前只翻这一页也值。

合上视频，自测一遍（能打勾才算学会）

- [ ] 我能不看资料写出：np.array([1, 2, 3.5]) 会整体变成 float64 —— 一个 float 就把全数组升成 float。
- [ ] 我能不看资料写出：a == np.nan 永远全 False，a != np.nan 永远全 True —— 这是最经典的错。
- [ ] 我能不看题源，把今天用到的每个函数「为什么要有它」说一遍
- [ ] 我能说出今天每个参数/返回值改了会怎样——换个写法结果差在哪
- [ ] 今天这几段代码我在本机都跑通、并看清了输出

这些句子都是「差一个字、结果差一截」的地方；三个勾以上，今天就算过关。

今天收工前，先知道明天学什么

第 9 天 • pandas 读数据 + Series/DataFrame + 一眼看清一张表

不用提前学。明天点「① 开始今天的学习」，会换上明天那份 PPT。

收工三件事（5 分钟）

- 今天没跑通的脚本存进 90-我的作业\，命名 2026-11-09-第08天-*.py
- 打卡表「③ 每日打卡」记一笔：今天卡在哪、错在哪（一句话就够）
- 错题明天重做一遍，练习数据在 60-练习环境\Python-Env\data