第 9 天 · 11/10 · 今日知识点回顾

pandas 读数据 + Series/DataFrame + 一眼看清一张表

目标：拿到任意一份 CSV，30 秒内说出：几行几列、每列什么类型、缺多少、数值列的范围。

对着 B 站视频看：视频讲到的每一句，这张 PPT 里都有一条；复习时只翻这份，不用再回去翻分P。

今天结束时，你应该能做到

验收标准（做到这句就算过关）

- 拿到任意一份 CSV，30 秒内说出：几行几列、每列什么类型、缺多少、数值列的范围。

今天的做法（顺序别颠倒）

- 题库地址：file:///D:/DSH工作区/00-学习中心/60-练习环境/Python-Env/data
- 做完记一句：今天卡在哪、错在哪 → 写进 3-每日打卡。

今天看哪几集、读哪一章

这一天的知识：4 集 • 合计约 42 分钟（边看边在本机敲一遍）

P15	Pandas2数据读取	约 14 分钟
P16	Pandas2读取CSV	约 16 分钟
P20	Pandas2数据信息查看操作	约 6 分钟
P21	Pandas2统计计算操作	约 6 分钟

教材（已下载到 20-教材与讲义\python-data\，断网也能看）

`https://raw.githubusercontent.com/datawhalechina/joyful-pandas/master/source/Content/ch2.rst`

第二章：文件的读取与写入、Series/DataFrame、常用基本函数

视频地址就在下面的「今天做哪些题」网页里，点一下直达分P。

知识点 1/7 • read_csv 的四个参数决定成败

- 一句话：encoding、dtype、parse_dates、na_values —— 四个参数一次给全，后面少踩一半坑。
- 代码：

```
import pandas as pd, pathlib
DATA = pathlib.Path(r'D:\DSH工作区\00-学习中心\60-练习环境\Python-Env\data')
df = pd.read_csv(DATA / 'orders_dirty.csv', encoding='utf-8-sig')
print(df.shape)          # (1200, 10)
print(list(df.columns))
print(df.dtypes)
```

★ 不加 encoding='utf-8-sig' 时，第一列列名会变成 '\ufefforder_id'，

- 后面 df['order_id'] 直接 KeyError: 'order_id' —— 报错信息里那个方框字符就是 BOM。

知识点 2/7 • head / info / describe / value_counts：四眼看全表

- 一句话：head 看长相、info 看类型和缺失、describe 看数值分布、value_counts 看分类计数。
- 代码：

```
print(df.head(3).to_string())
print(df.info())
print(df[['quantity']].describe().round(2))
print(df['status'].value_counts(dropna=False))
```

★ info() 输出的「Non-Null Count」比总行数少多少，就是这一列缺多少。

- 比 isnull().sum() 更省一次调用，且一眼看到 dtype —— 脏数据最常见的错就是「金额列被读成了 object」。

知识点 3/7 • Series 和 DataFrame 的关系

- 一句话：DataFrame 是一张表；df['col'] 取出的是 Series（一列，带索引）。
- 代码：

```
s = df['city']
print(type(s))                  # <class 'pandas.Series'>
print(s.shape, s.dtype)         # (1200,) object
print(s.head(3).tolist())
print(df[['city']].shape)       # (1200, 1) ← 双层方括号拿到的是 DataFrame
```

★ df['city'] 是 Series，df[['city']] 是 DataFrame。两者长得像，但

- df['city'].mean() 能用、df[['city']].mean() 返回 Series —— 差一层方括号，行为不同。

这一页只讲「Series 和 DataFrame 的关系」。讲完就翻页，下一页是另一个知识点。

知识点 4/7 • 索引：默认 0..n-1，可以换

- 一句话：df.index 是行号，set_index 能把它换成业务主键。
- 代码：

```
print(df.index[:3])                      # RangeIndex(start=0, stop=3, step=1)
d2 = df.set_index('order_id')
print(d2.index[:3].tolist())
print(d2.loc[d2.index[0], ['city', 'amount']].to_dict())
```

★ set_index 之后 order_id 不再是普通列。想保留成列要用 reset_index() 还原，或者用 df.set_index('order_id', drop=False)。

知识点 5/7 • 真数据的「第一印象」：本机 1200 行订单

- 一句话：先跑一遍四眼，把所有异常记下来，别急着清洗。
- 代码：

```
print('行数', len(df))
print('重复 order_id', df['order_id'].duplicated().sum())      # 37
print('金额缺失', df['amount'].isna().sum())                   # 35
print('城市缺失', df['city'].isna().sum())                     # 56
print('状态取值', df['status'].unique())                       # 6 种写法
print('日期前缀分布', df['create_time'].astype(str).str[:4].value_counts().to_dict())
```

- （本机实测这 6 个数：1200 行 / 37 个重复单号 / 35 行金额空 / 56 行城市空 /status 有 PAID、Paid、paid、'paid '、pending、refunded 六种写法。
- 第 10 天就是专门洗这六个问题。）

这一页只讲「真数据的「第一印象」：本机 1200 行订单」。讲完就翻页，下一页是另一个知识点。

知识点 6/7 • 数值列的三种统计口径要分清

- 一句话：mean 跳过 nan，sum 也跳过 nan（pandas 默认 skipna=True），和 numpy 相反。
- 代码：

```
import numpy as np
s = pd.Series([1.0, np.nan, 3.0])
print(s.sum(), s.mean(), s.count(), len(s))    # 4.0 2.0 2 3
print(s.sum(skipna=False))                      # nan  ← 关掉跳过
```

★ 这条和 numpy 的 arr.sum() 行为相反**：numpy 遇 nan 就变 nan，pandas 默认跳过。**

- 混用两套 API 时，同一个「合计」会算出两个数。

知识点 7/7 • 读 Excel 只多一个参数

- 一句话：pd.read_excel(path, sheet_name=...)；不给 sheet_name 读第一个 sheet。
- 代码：

```
xl = pd.ExcelFile(DATA / 'sales_dirty.xlsx')
print(xl.sheet_names)                    # ['明细', '商品表', '城市表']
d = pd.read_excel(DATA / 'sales_dirty.xlsx', sheet_name='明细')
print(d.shape, list(d.columns))
```

★ 本机实测：明细 sheet 400 行 9 列，列名是「订单号/日期/城市/品类/商品/数量/单价/金额/销售员」。

- 读 Excel 比 CSV 慢 5–10 倍，能导出 CSV 就先导。

代码速查：今天这几段，要在本机跑通（1/3）

写一个 look_at_data.py，对三份数据各跑一遍「四眼」：

```
import pandas as pd, pathlib
```

```
DATA = pathlib.Path(r'D:\DSH工作区\00-学习中心\60-练习环境\Python-Env\data')
```

```
def look(path, **kw):
```

```
    df = pd.read_csv(path, encoding='utf-8-sig', **kw)
```

print('=' * 60)

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

代码速查：今天这几段，要在本机跑通（2/3）

```
    print(path.name, df.shape)
    print(df.dtypes.to_string())
    print('缺失: ', df.isna().sum()[df.isna().sum() > 0].to_dict())
    num = df.select_dtypes('number')
    if not num.empty:
        print(num.describe().round(2).to_string())
    return df
o = look(DATA / 'orders_dirty.csv')
u = look(DATA / 'users_dirty.csv')
```

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

代码速查：今天这几段，要在本机跑通（3/3）

e = look(DATA / 'events_dirty.csv')

验收（做到才算过关）：

① orders 报出 1200 行 10 列、37 个重复单号、35 行金额缺失、56 行城市缺失；

② users 报出 500 行 7 列，并说出 age 列的最大值是多少（提示：会有 999）；

③ 能说出为什么 amount 列被读成了 object 而不是 float64。

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

最容易错的地方

后面 df['order_id'] 直接 KeyError: 'order_id' —— 报错信息里那个方框字符就是 BOM。

比 isnull().sum() 更省一次调用，且一眼看到 dtype —— 脏数据最常见的错就是「金额列被读成了 object」。

这些句子都是「差一个字、结果差一截」的地方，考前只翻这一页也值。

合上视频，自测一遍（能打勾才算学会）

- [ ] 我能不看资料写出：info() 输出的「Non-Null Count」比总行数少多少，就是这一列缺多少。
- [ ] 我能不看资料写出：df['city'] 是 Series，df[['city']] 是 DataFrame。两者长得像，但
- [ ] 我能不看资料说出：一句话：encoding、dtype、parse_dates、na_values —— 四个参数一次给全，后面少踩一半坑。
- [ ] 我能不看资料说出：一句话：先跑一遍四眼，把所有异常记下来，别急着清洗。
- [ ] 我能不看题源，把今天用到的每个函数「为什么要有它」说一遍
- [ ] 我能说出今天每个参数/返回值改了会怎样——换个写法结果差在哪

这些句子都是「差一个字、结果差一截」的地方；三个勾以上，今天就算过关。

今天收工前，先知道明天学什么

第 10 天 • 清洗第一课：缺失值、重复行、类型转换、字符串规整

不用提前学。明天点「① 开始今天的学习」，会换上明天那份 PPT。

收工三件事（5 分钟）

- 今天没跑通的脚本存进 90-我的作业\，命名 2026-11-10-第09天-*.py
- 打卡表「③ 每日打卡」记一笔：今天卡在哪、错在哪（一句话就够）
- 错题明天重做一遍，练习数据在 60-练习环境\Python-Env\data