第 10 天 • 11/11 • 今日知识点回顾

清洗第一课：缺失值、重复行、类型转换、字符串规整

目标：把 1200 行脏订单洗成「类型全对、无重复、缺失有交代」的干净表，并写一份清洗账（每步丢了多少行、为什么）。

对着 B 站视频看：视频讲到的每一句，这张 PPT 里都有一条；复习时只翻这份，不用再回去翻分P。

今天结束时，你应该能做到

验收标准（做到这句就算过关）

- 把 1200 行脏订单洗成「类型全对、无重复、缺失有交代」的干净表，并写一份清洗账（每步丢了多少行、为什么）。

今天的做法（顺序别颠倒）

- 题库地址：file:///D:/DSH工作区/00-学习中心/60-练习环境/Python-Env/data
- 做完记一句：今天卡在哪、错在哪 → 写进 3-每日打卡。

今天看哪几集、读哪一章

这一天的知识：3 集 • 合计约 47 分钟（边看边在本机敲一遍）

P32	Pandas2数据清洗与准备	约 15 分钟
P25	Pandas2数据类型转换操作	约 8 分钟
P27	Pandas2数据添加修改删除操作	约 24 分钟

教材（已下载到 20-教材与讲义\python-data\，断网也能看）

`https://raw.githubusercontent.com/datawhalechina/joyful-pandas/master/source/Content/ch7.rst`

第七章 缺失数据：isna / dropna / fillna / 插值

视频地址就在下面的「今天做哪些题」网页里，点一下直达分P。

知识点 1/7 • isna 找缺失，dropna 删，fillna 填 —— 先想清楚删还是填

- 一句话：能算出来的缺失就填（金额=单价×数量），算不出来的才删；每一步都要记账。
- 代码：

```
import pandas as pd, numpy as np, pathlib
DATA = pathlib.Path(r'D:\DSH工作区\00-学习中心\60-练习环境\Python-Env\data')
df = pd.read_csv(DATA / 'orders_dirty.csv', encoding='utf-8-sig')
print(df.isna().sum().to_dict())
print('删掉任一缺失的行：', len(df.dropna()))
print('只删 amount 缺的行：', len(df.dropna(subset=['amount'])))
print('city 填空：', len(df['city'].fillna('（未知）')))
```

知识点 1/7 • isna 找缺失，dropna 删，fillna 填 —— 先想清楚删还是填（续）

★ dropna() 不给参数是「任一行有任一缺失就删」—— 本机这 1200 行里会被删掉 90 行（35 金额 + 56 城市，可能有重叠）。先 dropna(subset=[...])

- 指定列，别一上来就 dropna()。

知识点 2/7 • 类型转换：to_numeric(errors='coerce') 是主力

- 一句话：errors='coerce' 把转不了的值变成 nan（而不是抛异常），配合先洗字符串。
- 代码：

```
s = df['amount'].astype(str).str.replace('¥', '', regex=False).str.replace(',', '', regex=False)
df['amount'] = pd.to_numeric(s, errors='coerce')
print(df['amount'].dtype, df['amount'].isna().sum())    # float64 35
# 对照：不加 coerce 会直接抛错
# pd.to_numeric(df['amount'])  →  ValueError: Unable to parse string "¥1,899.00"
```

★ 报错原文：ValueError: Unable to parse string "¥1,899.00" at position 3。

- 「at position 3」告诉你第 3 行有问题，但真实数据里往往是几千行都有问题 ——所以一律先 coerce 再统计，别指望它一行行报。

这一页只讲「类型转换：to_numeric(errors='coerce') 是主力」。讲完就翻页，下一页是另一个知识点。

知识点 3/7 • 字符串规整三件套：strip / lower / replace

- 一句话：前后空格、大小写、内部空格 —— 清洗状态列时必须三样都做。
- 代码：

```
print(df['status'].unique())                    # 6 种写法
df['status'] = df['status'].astype(str).str.strip().str.lower()
print(df['status'].value_counts().to_dict())
# {'paid': 417, 'pending': 406, 'refunded': 377}
```

★ 'paid ' 和 'paid' 在 groupby 里是两组 —— 这一条错，第 12 天的品类汇总会多出一行、金额少一截，而且不报错。

知识点 4/7 • drop_duplicates：先想清楚「重复」的定义

- 一句话：drop_duplicates(subset=['order_id'], keep='first') 按业务主键去重。
- 代码：

```
print('重复单号行数：', df['order_id'].duplicated().sum())      # 37
before = len(df)
df = df.drop_duplicates(subset=['order_id'], keep='first').reset_index(drop=True)
print('去重：', before, '→', len(df))                            # 1200 → 1163
```

★ 不给 subset 是「整行完全相同才删」—— 本机这 1200 行的整行重复是 0 行，所以 df.drop_duplicates() 一行都不会删。业务上说的「重复」几乎都是主键重复，一定要给 subset。

知识点 5/7 • 日期解析：本机这份数据有 145 行中文日期，format='mixed' 救不了

- 一句话：中文日期（2026年8月1日）必须单独用 format='%Y年%m月%d日' 再解析。
- 代码：

```
ct = df['create_time'].astype(str)
print(ct.str.contains('年').sum())                  # 145
a = pd.to_datetime(ct, format='mixed', errors='coerce')
print('mixed 解析失败：', a.isna().sum())            # 145
cn = pd.to_datetime(ct, format='%Y年%m月%d日 %H:%M:%S', errors='coerce')
print('中文格式单独解析成功：', cn.notna().sum())
```

知识点 5/7 • 日期解析：本机这份数据有 145 行中文日期，format='mixed' 救不了...

★ 本机实测：pandas 3.0.6 的 format='mixed' 也不认「2026年8月1日」，

- 145 行全部变 NaT。必须先用 str.replace('年','-').replace('月','-').replace('日','')
- 或单独指定 format。这是「看起来能跑、结果悄悄少了 145 行」的典型。

知识点 6/7 • 日期统一成标准格式：一次 replace 解决

- 一句话：把「年月日」换成「-」，再统一 parse，比写三个分支简单。
- 代码：

```
norm = (ct.str.replace('年', '-', regex=False)
.str.replace('月', '-', regex=False)
.str.replace('日', '', regex=False)
.str.replace('/', '-', regex=False))
df['create_time'] = pd.to_datetime(norm, format='mixed', errors='coerce')
print(df['create_time'].isna().sum())          # 0
print(df['create_time'].min(), df['create_time'].max())
```

- （本机实测：清洗后 1163 行日期全部解析成功，范围 2026-08-01 到 2026-10-29。
- 注意「只有日期没有时间」的 42 行会被补成 00:00:00 —— 这是对的，但如果按小时做分析，要单独标出来。）

知识点 7/7 • 清洗账：每步都记一笔，最后一起打印

- 一句话：用 dict 记 {步骤: 影响行数}，跑完打印 —— 这是能拿去面试讲的「清洗口径」。
- 代码：

```
log = {}
log['原始行数'] = len(df)
```

知识点 7/7 • 清洗账：每步都记一笔，最后一起打印（续）

- log['去重删除'] = 37log['金额无法解析'] = int(df['amount'].isna().sum())
- log['日期无法解析'] = int(df['create_time'].isna().sum())
- log['城市缺失已填'] = int((df['city'] == '（未知）').sum())

```
for k, v in log.items():
print(f'{k:12s}{v:>6d}')
```

★ 面试问「你怎么处理脏数据」时，答「我有 6 条规则，每条影响多少行」比答「我用了 dropna 和 fillna」高一个量级 —— 因为前者证明你量过**。**

代码速查：今天这几段，要在本机跑通（1/8）

写 clean_orders_v2.py，产出 clean_v2.csv + clean_log.json：

```
import json, pathlib
```

```
import pandas as pd
```

```
DATA = pathlib.Path(r'D:\DSH工作区\00-学习中心\60-练习环境\Python-Env\data')
```

```
def clean(path):
```

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

代码速查：今天这几段，要在本机跑通（2/8）

```
    df = pd.read_csv(path, encoding='utf-8-sig')
```

log = {'raw_rows': len(df)}

1) 金额

```
    s = (df['amount'].astype(str).str.replace('¥', '', regex=False)
```

```
           .str.replace(',', '', regex=False))
```

```
    df['amount'] = pd.to_numeric(s, errors='coerce')
```

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

代码速查：今天这几段，要在本机跑通（3/8）

```
    log['amount_na'] = int(df['amount'].isna().sum())
```

2) 状态规整

```
    df['status'] = df['status'].astype(str).str.strip().str.lower()
```

3) 城市填空

```
    df['city'] = df['city'].fillna('（未知）').str.strip().replace('', '（未知）')
```

```
    log['city_filled'] = int((df['city'] == '（未知）').sum())
```

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

代码速查：今天这几段，要在本机跑通（4/8）

```
# 4) 日期统一

ct = df['create_time'].astype(str)

    norm = (ct.str.replace('年', '-', regex=False)

               .str.replace('月', '-', regex=False)

               .str.replace('日', '', regex=False)

               .str.replace('/', '-', regex=False))
```

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

代码速查：今天这几段，要在本机跑通（5/8）

```
df['create_time'] = pd.to_datetime(norm, format='mixed', errors='coerce')
```

```
log['time_na'] = int(df['create_time'].isna().sum())
```

5) 去重

before = len(df)

```
df = df.drop_duplicates(subset=['order_id'], keep='first').reset_index(drop=True)
```

```
log['dup_dropped'] = before - len(df)
```

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

代码速查：今天这几段，要在本机跑通（6/8）

```
    # 6) 数量：负数当录入错误，置空
    neg = int((df['quantity'] < 0).sum())
    df.loc[df['quantity'] < 0, 'quantity'] = pd.NA
    log['qty_negative'] = neg
    log['clean_rows'] = len(df)
    return df, log

if __name__ == '__main__':
```

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

代码速查：今天这几段，要在本机跑通（7/8）

```
df, log = clean(DATA / 'orders_dirty.csv')
```

```
df.to_csv(DATA / 'clean_v2.csv', index=False, encoding='utf-8-sig')
```

```
(DATA / 'clean_log.json').write_text(
```

```
    json.dumps(log, ensure_ascii=False, indent=2), encoding='utf-8')
```

```
print(json.dumps(log, ensure_ascii=False, indent=2))
```

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

代码速查：今天这几段，要在本机跑通（8/8）

```
print(df.dtypes)
```

验收（做到才算过关）：

① 六个数字对得上：raw 1200 / amount_na 35 / city_filled 56 / time_na 0 / dup 37 / clean 1163；

② df.dtypes 里 amount 是 float64、create_time 是 datetime64[ns]；

③ 能解释「为什么去重放在日期清洗之后、数量置空之前」——顺序影响 clean_rows。

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

最容易错的地方（1/2）

指定列，别一上来就 dropna()。

★ 报错原文：ValueError: Unable to parse string "¥1,899.00" at position 3。

「at position 3」告诉你第 3 行有问题，但真实数据里往往是几千行都有问题 ——所以一律先 coerce 再统计，别指望它一行行报。

★ 'paid ' 和 'paid' 在 groupby 里是两组 —— 这一条错，第 12 天的品类汇总会多出一行、金额少一截，而且不报错。

这些句子都是「差一个字、结果差一截」的地方，考前只翻这一页也值。

最容易错的地方（2/2）

> 注意「只有日期没有时间」的 42 行会被补成 00:00:00 —— 这是对的，但如果按小时做分析，要单独标出来。）

这些句子都是「差一个字、结果差一截」的地方，考前只翻这一页也值。

合上视频，自测一遍（能打勾才算学会）

- [ ] 我能不看资料写出：'paid ' 和 'paid' 在 groupby 里是两组 —— 这一条错，第 12 天的品类汇总会多出一行、金额少一截，而且不报错。
- [ ] 我能不看资料说出：「at position 3」告诉你第 3 行有问题，但真实数据里往往是几千行都有问题 ——所以一律先 coerce 再统计，别指望它一行行报。
- [ ] 我能不看资料说出：一句话：前后空格、大小写、内部空格 —— 清洗状态列时必须三样都做。
- [ ] 我能不看资料说出：一句话：中文日期（2026年8月1日）必须单独用 format='%Y年%m月%d日' 再解析。
- [ ] 我能不看资料说出：145 行全部变 NaT。必须先用 str.replace('年','-').replace('月','-').replace('日','')
- [ ] 我能不看题源，把今天用到的每个函数「为什么要有它」说一遍

这些句子都是「差一个字、结果差一截」的地方；三个勾以上，今天就算过关。

今天收工前，先知道明天学什么

第 11 天 • 筛选与排序：布尔索引、query、loc/iloc、多列排序

不用提前学。明天点「① 开始今天的学习」，会换上明天那份 PPT。

收工三件事（5 分钟）

- 今天没跑通的脚本存进 90-我的作业\，命名 2026-11-11-第10天-*.py
- 打卡表「③ 每日打卡」记一笔：今天卡在哪、错在哪（一句话就够）
- 错题明天重做一遍，练习数据在 60-练习环境\Python-Env\data