第 12 天 • 11/13 • 今日知识点回顾

groupby 分组聚合：agg、transform、多列分组

目标：给出「每个品类每个城市的实付合计与订单数」，并说清 agg 和 transform 的结果形状差别。

对着 B 站视频看：视频讲到的每一句，这张 PPT 里都有一条；复习时只翻这份，不用再回去翻分P。

今天结束时，你应该能做到

验收标准（做到这句就算过关）

- 给出「每个品类每个城市的实付合计与订单数」，并说清 agg 和 transform 的结果形状差别。

今天的做法（顺序别颠倒）

- 题库地址：file:///D:/DSH工作区/00-学习中心/60-练习环境/Python-Env/data
- 做完记一句：今天卡在哪、错在哪 → 写进 3-每日打卡。

今天看哪几集、读哪一章

这一天的知识：3 集 • 合计约 37 分钟（边看边在本机敲一遍）

P34	Pandas2数据分组与聚合	约 6 分钟
P33	【数据的合并和分组聚合】03数据分组聚合	约 15 分钟
P34	【数据的合并和分组聚合】04数据分组聚合02	约 16 分钟

教材（已下载到 20-教材与讲义\python-data\，断网也能看）

`https://raw.githubusercontent.com/datawhalechina/joyful-pandas/master/source/Content/ch4.rst`

第四章 分组：groupby 的三大操作（聚合/变换/过滤）

视频地址就在下面的「今天做哪些题」网页里，点一下直达分P。

知识点 1/7 • groupby 三步：拆、算、合

- 一句话：df.groupby('列')['要算的列'].agg(函数) —— 拆开、每块算、拼回来。
- 代码：

```
import pandas as pd, pathlib
DATA = pathlib.Path(r'D:\DSH工作区\00-学习中心\60-练习环境\Python-Env\data')
df = pd.read_csv(DATA / 'clean_v2.csv', encoding='utf-8-sig')
paid = df[df['status'] == 'paid']
g = paid.groupby('category')['amount'].agg(['count', 'sum', 'mean']).round(2)
print(g.sort_values('sum', ascending=False).to_string())
```

这一页只讲「groupby 三步：拆、算、合」。讲完就翻页，下一页是另一个知识点。

知识点 1/7 • groupby 三步：拆、算、合（续）

★ 结果（本机实测）：数码 132 单 / 192,231.00 / 均价 1,456.30；

- 家居 113 单 / 147,895.00 / 1,308.81；美妆 74 单 / 59,704.00 / 806.81；
- 食品 85 单 / 22,606.00 / 265.95。四个数加起来 = 422,436.00 = 昨天的 paid 合计。

知识点 2/7 • as_index=False 让分组键留在列里

- 一句话：groupby(..., as_index=False) 等价于 .reset_index()，少写一步。
- 代码：

```
t = paid.groupby('city', as_index=False)['amount'].sum().sort_values('amount', ascending=False)
print(t.head(3).to_string(index=False))
print(t.columns.tolist())      # ['city', 'amount']
```

★ 不加 as_index=False 时，city 变成索引，后面 to_csv 会丢一列 ——这是「导出的文件少一列」最常见的原因。

知识点 3/7 • 命名聚合：一个列一次算多个指标，输出列名自己定

- 一句话：agg(总单数=('order_id', 'count'), 实付=('amount', 'sum'))。
- 代码：

```
r = paid.groupby('city').agg(
总单数=('order_id', 'count'),
实付合计=('amount', 'sum'),
客单价=('amount', 'mean'),
最大单=('amount', 'max'),
).round(2).sort_values('实付合计', ascending=False)
print(r.head(5).to_string())
```

★ 命名聚合要求 pandas ≥ 0.25，本机 3.0.6 完全支持。老写法agg({'amount': ['sum', 'mean']}) 会得到多级列名，导出 CSV 后表头是两行 ——给业务看时一律用命名聚合。

知识点 4/7 • transform：算完把结果「铺回原表的每一行」

- 一句话：agg 每个组返回一行；transform 每个组返回和原组一样多的行。
- 代码：

```
df['city_total'] = df.groupby('city')['amount'].transform('sum')
df['city_share'] = (df['amount'] / df['city_total'] * 100).round(2)
print(df[['order_id', 'city', 'amount', 'city_total', 'city_share']].head(5).to_string(index=False))
```

★ 用 agg 做这件事要先 merge 回去，transform 一步到位 —— 算「占比」时必用。

- 注意分母含 nan 时结果是 nan，要先用 fillna(0) 或只对 paid 算。

知识点 5/7 • 多列分组 + 交叉表

- 一句话：groupby(['城市', '品类']) 得到多层索引，unstack() 摊成二维表。
- 代码：

```
pv = (paid.groupby(['city', 'category'])['amount'].sum()
.unstack(fill_value=0).round(0))
print(pv.shape)                                  # (9, 4)
print(pv.sum(axis=1).sort_values(ascending=False).head(3).to_string())
```

★ 本机实测：9 个城市 × 4 个品类，实付合计最高的城市是南京（60,532.00）。

- 这个结果第 15 天用 pivot_table 会再算一次，两个数必须一致。

知识点 6/7 • size 与 count 的差别（老坑）

- 一句话：size 数「行数（含 nan）」，count 数「非 nan 的个数」。
- 代码：

```
print(paid.groupby('city').size().head(3).to_string())
print(paid.groupby('city')['amount'].count().head(3).to_string())
```

★ 只要有一个金额是 nan，这两个数就不一样。回答「一共多少单」时，永远用 size() 或 count 在非空列上 —— 否则会少算。

知识点 7/7 • groupby 的两个性能与正确性开关

- 一句话：observed=True（分类列只保留出现过的组合）、sort=False（不排序更快）。
- 代码：

```
df['city'] = df['city'].astype('category')
print(len(df.groupby(['city', 'category'], observed=True)))
print(len(df.groupby(['city', 'category'], observed=False)))   # 笛卡尔积，可能更大
```

这一页只讲「groupby 的两个性能与正确性开关」。讲完就翻页，下一页是另一个知识点。

知识点 7/7 • groupby 的两个性能与正确性开关（续）

- （pandas 3.0 的 groupby 默认 observed=True 了，但显式写出来更保险；

```
observed=False 时分类列会补齐所有组合，行数暴涨且大量为 0 —
```

- 这是「分组结果莫名其妙多了几百行」的元凶。）

这一页只讲「groupby 的两个性能与正确性开关」。讲完就翻页，下一页是另一个知识点。

代码速查：今天这几段，要在本机跑通（1/5）

写 groupby_practice.py，产出五个能直接贴进报告的表：

```
import pandas as pd, pathlib
```

```
DATA = pathlib.Path(r'D:\DSH工作区\00-学习中心\60-练习环境\Python-Env\data')
```

```
df = pd.read_csv(DATA / 'clean_v2.csv', encoding='utf-8-sig')
```

paid = df[df['status'] == 'paid']

```
# 1) 品类汇总（对照本机数字：数码 192231 / 家居 147895 / 美妆 59704 / 食品 22606）
```

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

代码速查：今天这几段，要在本机跑通（2/5）

```
print(paid.groupby('category').agg(
```

```
    单数=('order_id', 'count'), 实付=('amount', 'sum'), 客单价=('amount', 'mean')
```

```
).round(2).sort_values('实付', ascending=False).to_string())
```

2) 城市汇总，as_index=False

```
print(paid.groupby('city', as_index=False)['amount'].sum()
```

代码速查：今天这几段，要在本机跑通（3/5）

```
        .sort_values('amount', ascending=False).head(5).to_string(index=False))
```

3) 城市 × 品类 交叉（unstack）

```
print(paid.groupby(['city', 'category'])['amount'].sum()
```

```
        .unstack(fill_value=0).round(0).to_string())
```

4) 每个订单占所在城市实付的百分比（transform）

```
df['city_total'] = df.groupby('city')['amount'].transform('sum')
```

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

代码速查：今天这几段，要在本机跑通（4/5）

```
df['share'] = (df['amount'] / df['city_total'] * 100).round(2)
```

```
print(df.nlargest(5, 'share')[['order_id', 'city', 'amount', 'city_total', 'share']]
```

.to_string(index=False))

```
# 5) 每个城市的 Top1 订单（groupby + nlargest 的组合写法）
```

```
print(paid.sort_values('amount', ascending=False)
```

代码速查：今天这几段，要在本机跑通（5/5）

```
        .groupby('city').head(1)[['city', 'order_id', 'amount']]
```

```
        .sort_values('amount', ascending=False).to_string(index=False))
```

验收（做到才算过关）：

① 第 1 题四个品类的实付合计相加 = 422,436.00；

② 第 3 题交叉表是 9 行 × 4 列，合计最高的城市是南京；

③ 能说清 transform 和 agg 的结果形状差别，并各举今天代码里的一处用法。

最容易错的地方

> 注意分母含 nan 时结果是 nan，要先用 fillna(0) 或只对 paid 算。

这些句子都是「差一个字、结果差一截」的地方，考前只翻这一页也值。

合上视频，自测一遍（能打勾才算学会）

- [ ] 我能不看资料写出：不加 as_index=False 时，city 变成索引，后面 to_csv 会丢一列 ——这是「导出的文件少一列」最常见的原因。
- [ ] 我能不看资料写出：用 agg 做这件事要先 merge 回去，transform 一步到位 —— 算「占比」时必用。
- [ ] 我能不看资料写出：只要有一个金额是 nan，这两个数就不一样。回答「一共多少单」时，永远用 size() 或 count 在非空列上 —— 否则会少算。
- [ ] 我能不看资料说出：注意分母含 nan 时结果是 nan，要先用 fillna(0) 或只对 paid 算。
- [ ] 我能不看资料说出：这个结果第 15 天用 pivot_table 会再算一次，两个数必须一致。
- [ ] 我能不看题源，把今天用到的每个函数「为什么要有它」说一遍

这些句子都是「差一个字、结果差一截」的地方；三个勾以上，今天就算过关。

今天收工前，先知道明天学什么

第 13 天 • merge 连接：how 四种取值、连接键对不上怎么办

不用提前学。明天点「① 开始今天的学习」，会换上明天那份 PPT。

收工三件事（5 分钟）

- 今天没跑通的脚本存进 90-我的作业\，命名 2026-11-13-第12天-*.py
- 打卡表「③ 每日打卡」记一笔：今天卡在哪、错在哪（一句话就够）
- 错题明天重做一遍，练习数据在 60-练习环境\Python-Env\data