第 14 天 • 11/15 • 今日知识点回顾

★W5 总验收：给一份脏 CSV，独立清洗成可分析表并说清每一步

目标：90 分钟内从 orders_dirty.csv 走到一份能交给别人的汇总表 + 一段 200 字的清洗说明，中途不查教程。

对着 B 站视频看：视频讲到的每一句，这张 PPT 里都有一条；复习时只翻这份，不用再回去翻分P。

今天结束时，你应该能做到

验收标准（做到这句就算过关）

- 90 分钟内从 orders_dirty.csv 走到一份能交给别人的汇总表 + 一段 200 字的清洗说明，中途不查教程。

今天的做法（顺序别颠倒）

- 题库地址：file:///D:/DSH工作区/00-学习中心/60-练习环境/Python-Env/data
- 做完记一句：今天卡在哪、错在哪 → 写进 3-每日打卡。

今天看哪几集、读哪一章

这一天的知识：3 集 • 合计约 20 分钟（边看边在本机敲一遍）

P28	Pandas2高级查询过滤	约 4 分钟
P29	Pandas2数据迭代操作	约 6 分钟
P30	Pandas2高级函数应用	约 10 分钟

教材（已下载到 20-教材与讲义\python-data\，断网也能看）

`https://raw.githubusercontent.com/datawhalechina/joyful-pandas/master/source/Content/ch1.rst`

回看第一章「列表推导式」那一节，检查自己是不是还在写 for + append

知识点 1/5 • 验收的判据是「能复现」，不是「跑通一次」

- 一句话：同一份脚本换个数据目录还能跑出结果，才算真会；只在自己电脑上跑通一次不算。
- 代码：

```
import pathlib, sys
DATA = pathlib.Path(sys.argv[1]) if len(sys.argv) > 1 else pathlib.Path(
r'D:\DSH工作区\00-学习中心\60-练习环境\Python-Env\data')
print('数据目录：', DATA, DATA.exists())
```

★ 把路径写死在代码里，是「换个环境就跑不了」的第一大原因。

- 今天所有脚本都改成命令行参数或环境变量。

这一页只讲「验收的判据是「能复现」，不是「跑通一次」」。讲完就翻页，下一页是另一个知识点。

知识点 2/5 • 清洗口径要写成「可复查的数字」，不是形容词

- 一句话：不说「有很多重复」，说「37 个重复单号，按 first 保留」。
- 代码：

```
LOG = {
'raw_rows': 1200,
'dup_order_id': 37,
'amount_unparsable': 35,
'city_missing': 56,
'time_cn_format': 145,
'qty_negative': 25,
'clean_rows': 1163,
```

这一页只讲「清洗口径要写成「可复查的数字」，不是形容词」。讲完就翻页，下一页是另一个知识点。

知识点 2/5 · 清洗口径要写成「可复查的数字」，不是形容词（续）

- }

```
for k, v in LOG.items():
print(f'{k:20s}{v:>6d}')
```

★ 这七个数字就是今天要背下来的「清洗口径」。面试被问「你洗过什么脏数据」时，报数字比报函数名有说服力。

知识点 3/5 • 汇总表要能回答一个业务问题

- 一句话：每个输出表都要对应一句「谁看了会做什么决定」。
- 代码：

```
paid = df[df['status'] == 'paid']
out = (paid.groupby(['city', 'category'])
.agg(单数=('order_id', 'count'), 实付=('amount', 'sum'))
.round(2).reset_index())
print(out.sort_values('实付', ascending=False).head(8).to_string(index=False))
```

★ 「城市 × 品类」这张表的业务问题：哪些城市在哪个品类上还有空间?

- 南京 60,532 排第一，但如果它只在数码上强、家居弱，那就是铺货问题。

知识点 4/5 • 验收脚本的结构：一个文件、四段、能重跑

- 一句话：load / clean / analyze / report 四段，main 里只做编排，每段可单独测。
- 代码：

```
def main(argv):
data_dir = pathlib.Path(argv[1]) if len(argv) > 1 else DEFAULT
raw = load(data_dir / 'orders_dirty.csv')
clean, log = clean(raw)
tables = analyze(clean)
report(clean, tables, log, data_dir / 'w5_report')
print('完成：', log)
```

- （今天产出的 w5_report/ 目录里应该有：clean.csv、summary_city_category.csv、summary_category.csv、clean_log.json —— 四个文件，缺一个都算没做完。）

这一页只讲「验收脚本的结构：一个文件、四段、能重跑」。讲完就翻页，下一页是另一个知识点。

知识点 5/5 • 自查清单：这 8 条全过才算 W5 过关

- 一句话：逐条打勾，别靠「感觉学会了」。
- 代码：

```
CHECK = [
'能不看资料写出 groupby + agg + 命名聚合',
'能说清 agg 与 transform 的结果形状差别',
'能说清 merge 的 how 四种取值的差别',
'能解释为什么 loc[0:2] 是 3 行、iloc[0:2] 是 2 行',
'能把三种日期格式统一成 datetime 且不丢行',
'能写出 6 条清洗规则并报出每一条影响多少行',
'能用 pivot_table 做一张城市 × 品类的交叉表',
'能给出一份 200 字的清洗说明，不含形容词只有数字',
```

知识点 5/5 • 自查清单：这 8 条全过才算 W5 过关（续）

-]

★ 8 条里有任何一条说不清，明天补 —— W6 的 pivot_table 和时间序列都建立在这上面。

这一页只讲「自查清单：这 8 条全过才算 W5 过关」。讲完就翻页，下一页是另一个知识点。

代码速查：今天这几段，要在本机跑通（1/7）

独立完成 w5_report.py（不许抄前面的代码），跑出四个文件：

结构示意，具体实现自己写

```
import json, pathlib, sys
```

```
import pandas as pd
```

```
DEFAULT = pathlib.Path(r'D:\DSH工作区\00-学习中心\60-练习环境\Python-Env\data')
```

```
def load(path):
```

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

代码速查：今天这几段，要在本机跑通（2/7）

```
    return pd.read_csv(path, encoding='utf-8-sig')
```

```
def clean(df):
```

```
    log = {}
```

```
    # 金额 / 状态 / 城市 / 日期 / 去重 / 数量 —— 六条规则，每条都记数
```

```
    ...
```

```
    return df, log
```

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

代码速查：今天这几段，要在本机跑通（3/7）

```
def analyze(df):
```

```
    paid = df[df['status'] == 'paid']
    return {
        'city_category': paid.groupby(['city', 'category'])
                             .agg(单数=('order_id', 'count'), 实付=('amount', 'sum'))
                             .round(2).reset_index(),
```

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

代码速查：今天这几段，要在本机跑通（4/7）

```
        'category': paid.groupby('category')
```

```
                    .agg(单数=('order_id', 'count'), 实付=('amount', 'sum'),
```

```
                         客单价=('amount', 'mean'))
```

```
                    .round(2).reset_index(),
```

```
}
```

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

代码速查：今天这几段，要在本机跑通（5/7）

```
def report(df, tables, log, outdir):
```

```
    outdir.mkdir(parents=True, exist_ok=True)
```

```
    df.to_csv(outdir / 'clean.csv', index=False, encoding='utf-8-sig')
```

for k, t in tables.items():

```
        t.to_csv(outdir / f'summary_{k}.csv', index=False, encoding='utf-8-sig')
```

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

代码速查：今天这几段，要在本机跑通（6/7）

```
    (outdir / 'clean_log.json').write_text(
```

```
        json.dumps(log, ensure_ascii=False, indent=2), encoding='utf-8')
```

```
if __name__ == '__main__':
```

```
    d = pathlib.Path(sys.argv[1]) if len(sys.argv) > 1 else DEFAULT
```

raw = load(d / 'orders_dirty.csv')

clean_df, log = clean(raw)

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

代码速查：今天这几段，要在本机跑通（7/7）

```
    report(clean_df, analyze(clean_df), log, d / 'w5_report')
```

```
print(log)
```

验收（做到才算过关，这是 W5 的总验收）：

① 四个文件都产出，clean.csv 是 1163 行；

② 品类汇总四个数字相加 = 422,436.00；

③ 200 字清洗说明能背下来讲，只含数字不含形容词；

④ 把脚本里的 DEFAULT 改成一个不存在的目录再跑一次，报错信息要能看懂。

合上视频，自测一遍（能打勾才算学会）

- [ ] 我能不看资料写出：把路径写死在代码里，是「换个环境就跑不了」的第一大原因。
- [ ] 我能不看资料写出：这七个数字就是今天要背下来的「清洗口径」。面试被问「你洗过什么脏数据」时，报数字比报函数名有说服力。
- [ ] 我能不看资料说出：「城市 × 品类」这张表的业务问题：哪些城市在哪个品类上还有空间？
- [ ] 我能不看资料写出：8 条里有任何一条说不清，明天补 —— W6 的 pivot_table 和时间序列都建立在这上面。
- [ ] 我能不看题源，把今天用到的每个函数「为什么要有它」说一遍
- [ ] 我能说出今天每个参数/返回值改了会怎样——换个写法结果差在哪

这些句子都是「差一个字、结果差一截」的地方；三个勾以上，今天就算过关。

今天收工前，先知道明天学什么

第 15 天 • pivot_table 透视表：index/columns/values/aggfunc 四件套

不用提前学。明天点「① 开始今天的学习」，会换上明天那份 PPT。

收工三件事（5 分钟）

- 今天没跑通的脚本存进 90-我的作业\，命名 2026-11-15-第14天-*.py
- 打卡表「③ 每日打卡」记一笔：今天卡在哪、错在哪（一句话就够）
- 错题明天重做一遍，练习数据在 60-练习环境\Python-Env\data