第 20 天 • 11/21 • 今日知识点回顾

把 W4–W6 的脚本收成「一个能讲的项目」

目标：有一个 5 个文件的目录，能对着它讲 3 分钟：数据哪来、怎么洗、算出什么、结论是什么。

对着 B 站视频看：视频讲到的每一句，这张 PPT 里都有一条；复习时只翻这份，不用再回去翻分P。

今天结束时，你应该能做到

验收标准（做到这句就算过关）

- 有一个 5 个文件的目录，能对着它讲 3 分钟：数据哪来、怎么洗、算出什么、结论是什么。

今天的做法（顺序别颠倒）

- 题库地址：file:///D:/DSH工作区/00-学习中心/60-练习环境/Python-Env/data
- 做完记一句：今天卡在哪、错在哪 → 写进 3-每日打卡。

今天看哪几集、读哪一章

这一天的知识：2 集 • 合计约 30 分钟（边看边在本机敲一遍）

P97	模块和包	约 18 分钟
P93	异常的传递性	约 12 分钟

教材（已下载到 20-教材与讲义\python-data\，断网也能看）

`https://raw.githubusercontent.com/datawhalechina/joyful-pandas/master/source/Content/ch1.rst`

第一章的练习题：用列表推导式改写 for 循环

知识点 1/7 • 项目结构：5 个文件，一个 README

• 一句话：一个脚本（main）、一个模块（清洗）、一个模块（分析）、一个 README、一个输出目录。

• 代码：

• project/README.md ← 3 分钟能讲完的说明src/load.py ← 读数据src/clean.py ← 六条清洗规则 src/analyze.py ← 汇总与图表run.py ← 只做编排out/ ← 所有产物

★ 面试官翻你的 GitHub 时只看 README 和目录结构。一个 800 行的单文件即使能跑，也会被当成「作业」而不是「项目」。

知识点 2/7 • README 的四段：数据 / 方法 / 结果 / 局限

- 一句话：局限那一段最加分 —— 它证明你知道自己的分析边界在哪。
- 代码：

```
# 电商订单分析
## 数据
```

- 1200 行订单（2026-08 ~ 2026-10），含重复单号、缺失金额、三种日期格式。

知识点 2/7 • README 的四段：数据 / 方法 / 结果 / 局限（续）

```
## 方法
```

> • 6 条清洗规则（去重 37 / 金额解析 35 缺失 / 城市填空 56 / 日期统一 145 / 数量置空 25 / 状态规整 6→3），清洗后 1163 行。

```
## 结果
```

知识点 2/7 • README 的四段：数据 / 方法 / 结果 / 局限（续）

- paid 417 单，实付 422,436 元；数码占 45.5%，南京最高 60,532。

```
## 局限
```

- 样本仅 3 个月，无法判断季节性；39 单用户信息缺失，性别维度分析不完整。

★ 「局限」不是自曝其短，是防止被问倒。写了局限，面试官就不会往那儿问；

- 不写，他一定会问。

知识点 3/7 • 异常处理：让脚本在数据变了的时候「说人话」

- 一句话：读不到文件、缺列、类型不对，三种情况都要有明确报错。
- 代码：

知识点 3/7 • 异常处理：让脚本在数据变了的时候「说人话」（续）

```
import sys, pathlib, pandas as pd
def load(path: pathlib.Path) -> pd.DataFrame:
if not path.exists():
sys.exit(f'[错误] 找不到数据文件：{path}')
df = pd.read_csv(path, encoding='utf-8-sig')
need = {'order_id', 'amount', 'city', 'status', 'create_time'}
miss = need - set(df.columns)
if miss:
sys.exit(f'[错误] 缺列：{sorted(miss)}；实际列：{list(df.columns)}')
if len(df) == 0:
sys.exit('[错误] 文件是空的')
return df
```

> **★ sys.exit(字符串) 会打印到 stderr 并以退出码 1 结束 —— 这是「脚本给用户看」最简单的做法。比 traceback 友好得多。**

这一页只讲「异常处理：让脚本在数据变了的时候「说人话」」。讲完就翻页，下一页是另一个知识点。

知识点 4/7 • 参数化：三个入口参数就够

- 一句话：--data 数据目录、--out 输出目录、--top N；不给就用默认。
- 代码：

```
import argparse
p = argparse.ArgumentParser()
p.add_argument('--data', default=r'D:\DSH工作区\00-学习中心\60-练习环境\Python-Env\data')
p.add_argument('--out', default=None)
p.add_argument('--top', type=int, default=10)
a = p.parse_args()
print(a.data, a.out, a.top)
```

★ 用 argparse 而不是 sys.argv[1]，好处是 --help 自动生成、参数可乱序、

- 少传不报错。30 行以内的脚本也值得用。

知识点 5/7 • 日志：一行时间戳 + 一行结论

- 一句话：不用 logging 模块也能有日志 —— print 到文件，格式统一就够。
- 代码：

```
import datetime as dt
def log(msg, f=None):
line = f'[{dt.datetime.now():%H:%M:%S}] {msg}'
print(line)
if f: f.write(line + '\n')
with open('run.log', 'w', encoding='utf-8') as f:
log('开始清洗', f)
log(f'清洗后 {1163} 行', f)
```

知识点 5/7 • 日志：一行时间戳 + 一行结论（续）

★ 项目里的 print 要能回答「什么时候、做了什么、结果多少」。

- 「print('done')」在面试官眼里等于没有日志。

知识点 6/7 • 自查：这份项目能不能被别人跑起来

- 一句话：换一台电脑、只给数据目录，能不能一条命令出结果。
- 代码：
- python run.py --data D:\somewhere\data --out .\out

- （今天要验证的是「可移植」：把项目目录复制到另一个路径，数据目录指向60-练习环境\Python-Env\data，跑一条命令，out/ 里四个文件都在。）

这一页只讲「自查：这份项目能不能被别人跑起来」。讲完就翻页，下一页是另一个知识点。

知识点 7/7 • 三分钟讲法：背景 → 做了什么 → 结果 → 学到了什么

- 一句话：每段 45 秒，结果段必须有两个具体数字。
- 代码：
- 背景：想练「脏数据到结论」的全流程，选了自己造的电商订单数据。
- 做了什么：1200 行、6 类脏点，写了 6 条清洗规则 + 4 张汇总表 + 3 张图。
- 结果：paid 417 单 42.2 万，数码占 45.5%，南京最高 6 万；
- 漏斗浏览→加购 30%，加购→下单只有 14.8%，卡点在加购后。
- 学到：日期格式不统一时 format='mixed' 也会静默丢行，必须先规整字符串。

★ 「学到」那一段要讲一个具体的坑**，不要讲「学会了 pandas」。**

- 讲坑 = 你真的做过；讲功能名 = 你看了教程。

代码速查：今天这几段，要在本机跑通（1/2）

把 W4–W6 的脚本收成一个目录 py-portfolio/order-analysis/：

py-portfolio/order-analysis/

README.md

run.py

src/__init__.py

src/load.py

src/clean.py

src/analyze.py

out/　　← 跑完才有

验收（做到才算过关）：

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

代码速查：今天这几段，要在本机跑通（2/2）

① 复制整个目录到 D:\temp_test\，改 --data 指回练习数据，一条命令出 4 个产物；

② README 四段齐全，「局限」段不少于 2 条；

③ 对着 README 讲 3 分钟，计时器计时，不超 3 分 30 秒。

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

最容易错的地方

样本仅 3 个月，无法判断季节性；39 单用户信息缺失，性别维度分析不完整。

少传不报错。30 行以内的脚本也值得用。

这些句子都是「差一个字、结果差一截」的地方，考前只翻这一页也值。

合上视频，自测一遍（能打勾才算学会）

- [ ] 我能不看资料写出：面试官翻你的 GitHub 时只看 README 和目录结构。一个 800 行的单文件即使能跑，也会被当成「作业」而不是「项目」。
- [ ] 我能不看资料写出：sys.exit(字符串) 会打印到 stderr 并以退出码 1 结束 —— 这是「脚本给用户看」最简单的做法。比 traceback 友好得多。
- [ ] 我能不看资料写出：项目里的 print 要能回答「什么时候、做了什么、结果多少」。
- [ ] 我能不看资料写出：「学到」那一段要讲一个**具体的坑**，不要讲「学会了 pandas」。
- [ ] 我能不看题源，把今天用到的每个函数「为什么要有它」说一遍
- [ ] 我能说出今天每个参数/返回值改了会怎样——换个写法结果差在哪

这些句子都是「差一个字、结果差一截」的地方；三个勾以上，今天就算过关。

今天收工前，先知道明天学什么

第 21 天 • ★简历第一版 + W6 总验收

不用提前学。明天点「① 开始今天的学习」，会换上明天那份 PPT。

收工三件事（5 分钟）

- 今天没跑通的脚本存进 90-我的作业\，命名 2026-11-21-第20天-*.py
- 打卡表「③ 每日打卡」记一笔：今天卡在哪、错在哪（一句话就够）
- 错题明天重做一遍，练习数据在 60-练习环境\Python-Env\data