第 22 天 • 11/23 • 今日知识点回顾

统计专项：描述统计、抽样与置信区间、假设检验、P 值三种误用

目标：拿到两组数据，能判断该用 t 检验还是卡方，算完能正确解读 P 值，并说出三种常见的误用。

对着 B 站视频看：视频讲到的每一句，这张 PPT 里都有一条；复习时只翻这份，不用再回去翻分P。

今天结束时，你应该能做到

验收标准（做到这句就算过关）

- 拿到两组数据，能判断该用 t 检验还是卡方，算完能正确解读 P 值，并说出三种常见的误用。

今天的做法（顺序别颠倒）

- 题库地址：file:///D:/DSH工作区/00-学习中心/60-练习环境/Python-Env/data
- 做完记一句：今天卡在哪、错在哪 → 写进 3-每日打卡。

今天看哪几集、读哪一章

这一天的知识：5 集 • 合计约 68 分钟（边看边在本机敲一遍）

P1	总体均值与样本均值	约 12 分钟
P5	样本标准差与总体标准差	约 14 分钟
P25	中心极限定理	约 16 分钟
P30	置信区间	约 12 分钟
P36	假设检验与 P 值	约 14 分钟

教材（已下载到 20-教材与讲义\python-data\，断网也能看） https://raw.githubusercontent.com/datawhalechina/joyful-pandas/master/source/Content/ch2.rst

视频地址就在下面的「今天做哪些题」网页里，点一下直达分P。

知识点 1/7 • 描述统计的五个数，比「平均值」有用得多

- 一句话：均值、中位数、标准差、P25/P75、极值 —— 一起看才知道分布长什么样。
- 代码：

这一页只讲「描述统计的五个数，比「平均值」有用得多」。讲完就翻页，下一页是另一个知识点。

知识点 1/7 • 描述统计的五个数，比「平均值」有用得多（续）

```
import pandas as pd, numpy as np, pathlib
DATA = pathlib.Path(r'D:\DSH工作区\00-学习中心\60-练习环境\Python-Env\data')
df = pd.read_csv(DATA / 'clean_v2.csv', encoding='utf-8-sig')
a = df['amount'].dropna()
print('n', len(a))
print('均值', round(a.mean(), 2), '中位数', round(a.median(), 2))
print('标准差', round(a.std(), 2), '偏度', round(a.skew(), 3))
print(a.describe(percentiles=[.25, .5, .75, .9, .99]).round(2).to_string())
```

★ 本机实测：金额均值 ≈ 1,013，中位数 ≈ 674 —— 均值明显高于中位数，说明右偏（少数大单拉高均值）。只报均值会让业务方误判「客单价一千」，实际上「一半的订单在 674 以下」。

这一页只讲「描述统计的五个数，比「平均值」有用得多」。讲完就翻页，下一页是另一个知识点。

知识点 2/7 • 标准差 ddof：pandas 和 numpy 默认不一样

- 一句话：pandas 的 std() 默认 ddof=1（样本），numpy 的 std() 默认 ddof=0（总体）。
- 代码：

```
arr = a.to_numpy()
print('pandas std', round(a.std(), 4), 'ddof=0', round(a.std(ddof=0), 4))
print('numpy  std', round(arr.std(), 4), 'ddof=1', round(arr.std(ddof=1), 4))
```

★ 样本量大时差别很小（差 √(n/(n-1)) 倍），但两组数对不上时，第一个要查的就是 ddof。这个坑在 A/B 实验算标准误时会被放大。

知识点 3/7 • 标准误与置信区间：手算一遍

- 一句话：SE = s/√n；95% CI = 均值 ± 1.96×SE（大样本）。
- 代码：

```
n = len(a); m = a.mean(); s = a.std(ddof=1)
se = s / np.sqrt(n)
```

知识点 3/7 • 标准误与置信区间：手算一遍（续）

- lo, hi = m - 1.96 * se, m + 1.96 * se

```
print(f'n={n} 均值={m:.2f} SE={se:.2f} 95%CI=[{lo:.2f}, {hi:.2f}]')
```

★ 置信区间的正确解读是「反复抽样 100 次，约 95 次算出的区间会包含真值」，不是**「真值有 95% 概率落在这个区间里」。面试常考这一句。**

知识点 4/7 • t 检验：两组均值是否有差异

- 一句话：scipy.stats.ttest_ind(样本1, 样本2, equal_var=False) —— 默认 Welch，更稳。
- 代码：

```
from scipy import stats
paid = df[df['status'] == 'paid']
beijing = paid[paid['city'] == '北京']['amount'].dropna()
shanghai = paid[paid['city'] == '上海']['amount'].dropna()
t, p = stats.ttest_ind(beijing, shanghai, equal_var=False)
print(f'北京 n={len(beijing)} 均值={beijing.mean():.0f}')
print(f'上海 n={len(shanghai)} 均值={shanghai.mean():.0f}')
print(f't={t:.3f} p={p:.4f}')
```

知识点 4/7 • t 检验：两组均值是否有差异（续）

★ equal_var=True（Student）要求两组方差相等，真实数据很难满足；

• Welch（equal_var=False）是默认推荐。scipy 的 ttest_ind 默认是 equal_var=True，必须显式写 False —— 这是最容易漏的一个参数。

知识点 5/7 • 卡方检验：两个分类变量是否相关

- 一句话：pd.crosstab 出列联表，再 scipy.stats.chi2_contingency。
- 代码：

```
ct = pd.crosstab(paid['city'], paid['category'])
chi2, p, dof, exp = stats.chi2_contingency(ct)
print(f'chi2={chi2:.3f} p={p:.4f} dof={dof}')
print('期望频数最小值', round(exp.min(), 2))
```

★ 卡方的前提是「期望频数 ≥5」，本机 9×4 表里最小期望值如果小于 5，结论就不可靠，要合并类别或改用 Fisher 精确检验。

知识点 6/7 • P 值的三种误用（面试必问）

- 一句话：P 小 ≠ 效应大；P 大 ≠ 没差异；做了 20 次检验总有 1 次 P<0.05。
- 代码：

知识点 6/7 • P 值的三种误用（面试必问）（续）

```
# 误用 1：把 P 当效应量
#   P=0.001 只说明「不太可能是巧合」，不说明差异大。
#   要看效应量：Cohen's d = (m1-m2)/pooled_std
d = (beijing.mean() - shanghai.mean()) / np.sqrt((beijing.var() + shanghai.var()) / 2)
print('Cohen d =', round(d, 3))       # |d|<0.2 可忽略，0.5 中等，0.8 大
# 误用 2：P>0.05 就说「两组一样」
#   正确说法是「没有足够证据认为不同」，不是「证明相同」。
# 误用 3：多重比较不校正
#   做 20 次独立检验，至少一次 P<0.05 的概率 = 1-0.95^20 ≈ 64%
print('20 次检验的假阳性概率', round((1 - 0.95 ** 20) * 100, 1), '%')
```

★ 这三条是数据分析面试里「统计」部分的高频题。答得出「P 值不是效应量」这一句，基本就过关了。

这一页只讲「P 值的三种误用（面试必问）」。讲完就翻页，下一页是另一个知识点。

知识点 7/7 • 样本量：想检出多大差异，需要多少人

- 一句话：$n \approx 16 \times \sigma^2 / \Delta^2$（两组均值比较，α=0.05、power=0.8 的经验公式）。
- 代码：

```
sigma = a.std(ddof=1)
for delta in [50, 100, 200]:
n_need = int(np.ceil(16 * sigma ** 2 / delta ** 2))
print(f'想检出 {delta} 元的差异，每组需要 {n_need} 人')
```

- （本机 σ≈1,100：检出 100 元差异每组要约 1,900 人；检出 200 元约 480 人。
- 这就是「为什么小流量实验测不出小改进」的量化答案 ——明天做 A/B 设计时直接用这个公式。）

代码速查：今天这几段，要在本机跑通（1/6）

写 stats_practice.py，五道题都要打印数字：

```
import numpy as np, pandas as pd, pathlib
```

```
from scipy import stats
```

```
DATA = pathlib.Path(r'D:\DSH工作区\00-学习中心\60-练习环境\Python-Env\data')
```

```
df = pd.read_csv(DATA / 'clean_v2.csv', encoding='utf-8-sig')
```

paid = df[df['status'] == 'paid']

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

代码速查：今天这几段，要在本机跑通（2/6）

1) 描述统计：均值/中位数/偏度/分位数

a = df['amount'].dropna()

```
print(a.describe(percentiles=[.25, .5, .75, .9, .99]).round(2).to_string())
```

```
print('偏度', round(a.skew(), 3))
```

2) ddof 对比

```
print('pandas std', round(a.std(), 4), '| numpy std', round(a.to_numpy().std(), 4))
```

3) 95% 置信区间

代码速查：今天这几段，要在本机跑通（3/6）

```
n, m, s = len(a), a.mean(), a.std(ddof=1)
```

se = s / np.sqrt(n)

```
print(f'CI = [{m - 1.96*se:.2f}, {m + 1.96*se:.2f}]')
```

4) 两个城市金额差异：t 检验 + 效应量

g = paid.groupby('city')['amount']

```
top2 = paid['city'].value_counts().head(2).index.tolist()
```

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

代码速查：今天这几段，要在本机跑通（4/6）

```
x, y = g.get_group(top2[0]).dropna(), g.get_group(top2[1]).dropna()
```

```
t, p = stats.ttest_ind(x, y, equal_var=False)
```

```
d = (x.mean() - y.mean()) / np.sqrt((x.var() + y.var()) / 2)
```

```
print(f'{top2[0]} vs {top2[1]}: t={t:.3f} p={p:.4f} d={d:.3f}')
```

5) 卡方：城市与品类是否相关

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

代码速查：今天这几段，要在本机跑通（5/6）

```
ct = pd.crosstab(paid['city'], paid['category'])
```

```
chi2, p2, dof, exp = stats.chi2_contingency(ct)
```

```
print(f'chi2={chi2:.3f} p={p2:.4f} dof={dof} 最小期望={exp.min():.2f}')
```

验收（做到才算过关）：

① 第 1 题能说出「均值 > 中位数」代表右偏，并解释业务含义；

② 第 4 题 p 值和 Cohen d 都报出来，能说清「p 小但 d 小」意味着什么；

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

代码速查：今天这几段，要在本机跑通（6/6）

③ 第 5 题能判断卡方是否可用（看最小期望是否 ≥5）。

先自己在编辑器里写；卡住了再翻教材对答案，别一上来就抄。

最容易错的地方

★ 样本量大时差别很小（差 √(n/(n-1)) 倍），但两组数对不上时，第一个要查的就是 ddof。这个坑在 A/B 实验算标准误时会被放大。

★ 卡方的前提是「期望频数 ≥5」，本机 9×4 表里最小期望值如果小于 5，结论就不可靠，要合并类别或改用 Fisher 精确检验。

这些句子都是「差一个字、结果差一截」的地方，考前只翻这一页也值。

合上视频，自测一遍（能打勾才算学会）

- [ ] 我能不看资料写出：样本量大时差别很小（差 √(n/(n-1)) 倍），但两组数对不上时，第一个要查的就是 ddof。这个坑在 A/B 实验算标准误时会被放大。

- [ ] 我能不看资料写出：置信区间的正确解读是「反复抽样 100 次，约 95 次算出的区间会包含真值」，**不是**「真值有 95% 概率落在这个区间里」。面试常考这一句。

- [ ] 我能不看资料写出：卡方的前提是「期望频数 ≥5」，本机 9×4 表里最小期望值如果小于 5，结论就不可靠，要合并类别或改用 Fisher 精确检验。

- [ ] 我能不看资料写出：这三条是数据分析面试里「统计」部分的高频题。答得出「P 值不是效应量」这一句，基本就过关了。

- [ ] 我能不看题源，把今天用到的每个函数「为什么要有它」说一遍

- [ ] 我能说出今天每个参数/返回值改了会怎样，换个写法结果差在哪

这些句子都是「能复述」，结果是十题有九题是「当时以为会了」。

今天收工前，先知道明天学什么

第 23 天 • 上午 A/B 实验设计 + 下午指标体系（一天两段，各出 300 字）

不用提前学。明天点「① 开始今天的学习」，会换上明天那份 PPT。

收工三件事（5 分钟）

- 今天没跑通的脚本存进 90-我的作业\，命名 2026-11-23-第22天-*.py
- 打卡表「③ 每日打卡」记一笔：今天卡在哪、错在哪（一句话就够）
- 错题明天重做一遍，练习数据在 60-练习环境\Python-Env\data